

# Propozycja pracy dyplomowej

Filip Jaworski  
s196281

## System rozpoznawania stresu i stanów emocjonalnych na podstawie sygnałów biomedycznych z wykorzystaniem uczenia maszynowego

### 1. Cel projektu

Celem projektu jest opracowanie mobilnego systemu typu 'wearable' umożliwiającego rozpoznawanie stresu oraz stanów emocjonalnych użytkownika na podstawie sygnałów fizjologicznych pozyskiwanych z czujników noszonych na nadgarstku, oraz klatce piersiowej. Klasyfikacja stanów będzie realizowana przy użyciu modelu uczenia maszynowego wytrenowanego na publicznym zbiorze danych WESAD.

### 2. Zbiór danych WESAD

Zbiór WESAD (Wearable Stress and Affect Detection) zawiera dane z dwóch urządzeń rejestrujących sygnały biomedyczne w trakcie eksperymentu laboratoryjnego. Dane pochodzą równolegle z urządzenia na nadgarstku *Empatica E4* oraz urządzenia na klatce piersiowej *RespiBAN*.

#### Sygnały rejestrowane na nadgarstku (Empatica E4):

- **EDA** - aktywność elektrodermalna skóry nadgarstka (Electrodermal Activity)
- **PPG** - fotopletyzmografia (Photoplethysmography)
- **ACC** - przyspieszenie tułowia w 3 osiach (3-axis Accelerometer)
- **TEMP** - temperatura skóry nadgarstka

#### Sygnały rejestrowane na klatce piersiowej (RespiBAN):

- **RESP** - sygnał oddechowy (Respiration)
- **ECG** - elektrokardiografia (Electrocardiography)
- **EMG** - elektromiografia (Electromyography)
- **EDA** - aktywność elektrodermalna skóry klatki piersiowej (Electrodermal Activity)
- **TEMP** - temperatura skóry klatki piersiowej
- **ACC** - przyspieszenie nadgarstka w 3 osiach (3-axis Accelerometer)

Na potrzeby projektu przeprowadziłem analizę danych oraz segmentację na okna 10-sekundowe. Dataset posiada ok. 12.5h użytecznych danych, które po podzieleniu dają następującą ilość próbek

Stan (etykieta)	Liczba próbek (10-sekundowe okna czasowe)
baseline	1761
stress	996
amusement	557
meditation	1180
<b>Łącznie</b>	<b>4494</b>

Ze względu na ograniczoną liczbę danych do treningu, szczególnie w klasie *amusement*, oparłbym proces klasyfikacji na modelu boostingowym XGBoost, który lepiej radzi sobie przy niewielkiej liczbie próbek, nierównowadze klas oraz szumach pomiarowych typowych dla sygnałów fizjologicznych, a jednocześnie nie wymaga dużych zasobów obliczeniowych i pozwala na implementację na urządzeniach wbudowanych takich jak Raspberry Pi lub Jetson Nano.

### 3. Proponowane sensory do prototypu

#### Najważniejsze czujniki:

- **EDA** - zmiany przewodnictwa skóry (ważny wskaźnik reakcji stresowej)
- **PPG** -> **BVP** - określanie tętna (HR) i jego zmienności (HRV)
- **ACC** - analiza ruchu i filtracja artefaktów
- **TEMP** - sygnał wspierający opisujący trendy termiczne

#### Opcjonalne czujniki:

- **RESP** - zwiększa dokładność klasyfikacji. Wymaga opaski klatkowej i zwiększa złożoność implementacyjną
- **ECG** - zwiększa dokładność klasyfikacji. Wymaga opaski klatkowej i zwiększa złożoność implementacyjną

#### Czujniki obecne w badaniu, ale niekoniecznie potrzebne do prototypu:

- **EMG** - niski wpływ na klasyfikację stanów stresowych i em

#### 4. Model uczenia maszynowego

Ze względu na ograniczoną liczbę danych do treningu, szczególnie w klasie '*amusement*', oparłbym proces klasyfikacji na modelu boostingowym XGBoost, który lepiej radzi sobie przy niewielkiej liczbie próbek, nierównowadze klas oraz szumach pomiarowych typowych dla sygnałów fizjologicznych, a jednocześnie nie wymaga dużych zasobów obliczeniowych i pozwala na implementację na urządzeniach wbudowanych takich jak Raspberry Pi lub Jetson Nano.

#### 5. Wstępna architektura komunikacji systemu

Czujniki będą oparte na modułach ESP32 komunikujących się z jednostką obliczeniową za pomocą protokołu Bluetooth Low Energy (BLE). Jednostka obliczeniowa (Raspberry Pi lub Jetson Nano) będzie odpowiedzialna za odbiór danych, buforowanie okien czasowych, ekstrakcję cech oraz wykonanie klasyfikacji modelem XGBoost.

- 
1. [WESAD \(Wearable Stress and Affect Detection\)](#)
  2. [\(PDF\) Emotion Recognition Using a Siamese Model and a Late Fusion-Based Multimodal Method in the WESAD Dataset with Hardware Accelerators](#)